

# Obrada informacija

## Analiza multivarijatnih podataka - primjene u financijama

**Stjepan Begušić, Zvonko Kostanjčar**

Sveučilište u Zagrebu  
Fakultet elektrotehnike i računarstva

Ak. god. 2023./2024.

# Danas...

- 1 Uvod u financijska tržišta – podatci, povrat i rizik investicija
- 2 Neprekidne slučajne varijable – pojmovi iz vjerojatnosti i statistike
- 3 Portfelji i diverzifikacija rizika
- 4 Financijski vremenski nizovi i njihova statistička svojstva
- 5 Analiza glavnih komponenti

# Financijska tržišta – uvod

- **Tržište** – mjesto gdje se susreću kupci i prodavatelji kako bi razmjenili dobra ili usluge
- **Financijska tržišta** – razmjena kapitala (novac, dionice, obveznice, financijske vrijednosnice i izvedenice)
- **Burza** – organizirano (najčešće elektroničko) tržište gdje se trgovanje odvija po posebnim pravilima

Zašto investitori sudjeluju u financijskim tržištima:

- rast kapitala
- upravljanje rizikom

Čemu financijska tržišta doprinose u modernoj ekonomiji:

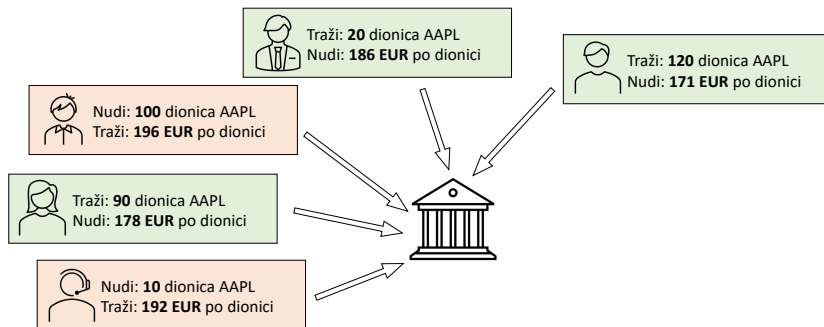
- likvidnost za uspješnu razmjenu kapitala
- definiranje cijena (price discovery)

# Financijska tržišta – burze nekad i danas



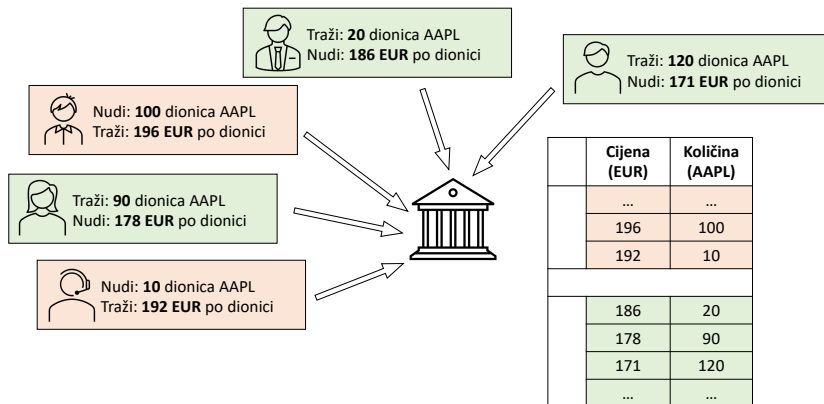
# Financijska tržišta – formiranje cijena u elektroničkim burzama

Ograničeni nalozi (limit order):



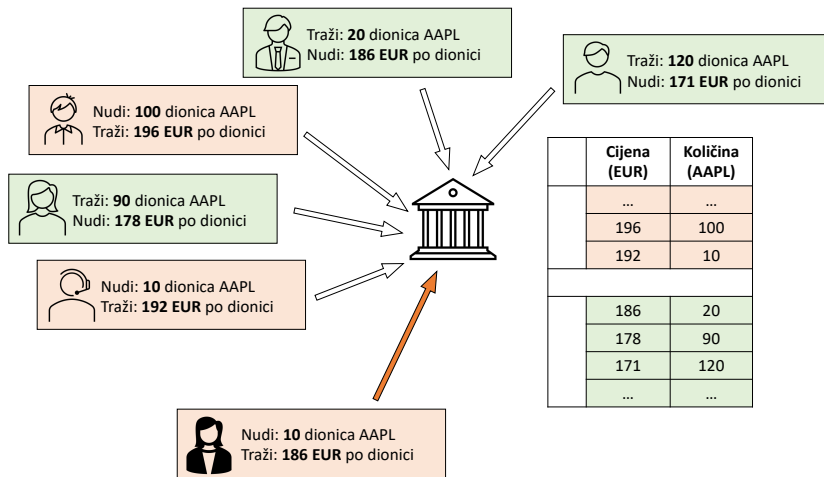
# Financijska tržišta – formiranje cijena u elektroničkim burzama

Knjiga ograničenih naloga (limit order book):



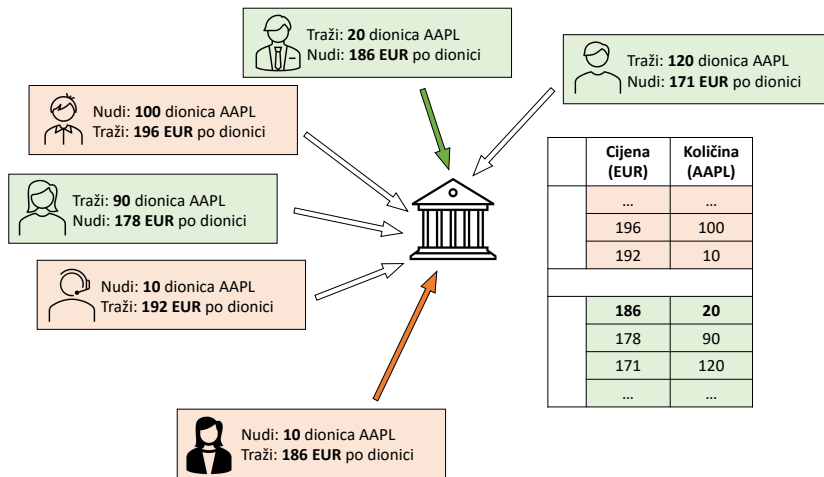
# Financijska tržišta – formiranje cijena u elektroničkim burzama

Burza djeluje kao posrednik koji spaja kupca i prodavatelja:



# Financijska tržišta – formiranje cijena u elektroničkim burzama

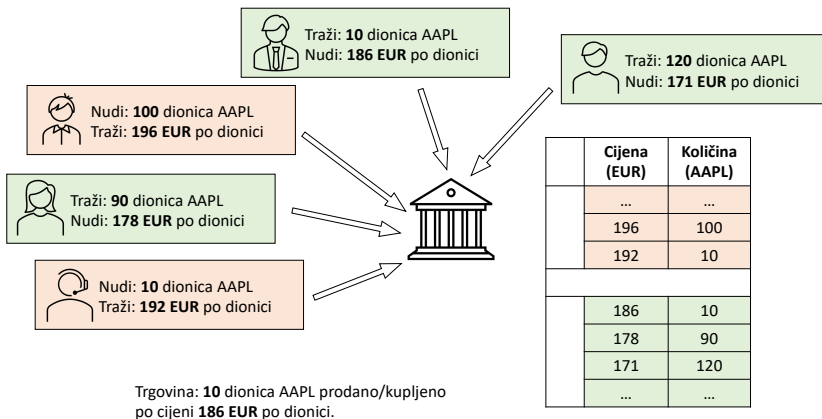
Burza djeluje kao posrednik koji spaja kupca i prodavatelja:





# Financijska tržišta – formiranje cijena u elektroničkim burzama

## Trgovanje:



# Financijska tržišta – formiranje cijena u elektroničkim burzama



Slika: Preuzeto s <http://finance.yahoo.com>.

# Financijska tržišta – cijene i povrati

Uzorkovanje cijena u fiksnim vremenskim intervalima (minute, sati, dani, mjeseci itd.):

- Open, High, Low, Close (OHLC)
- U kvantitativnoj analizi često se koriste zadnje cijene u intervalima

## Povrati

Aritmetički (linearni) povrat:

$$R(t) = \frac{P(t) - P(t-1)}{P(t-1)}$$


Logaritamski (kontinuirani) povrat:

$$r(t) = \log \left( \frac{P(t)}{P(t-1)} \right)$$

Zašto u analizi koristimo povrate, a ne cijene?

- Razina cijene vrijednosnice (npr. dionice) ne govori ništa o veličini ili vrijednosti kompanije
- Cijene s vremenom rastu ili padaju (nisu stacionarne)

# Financijska tržišta – cijene i povrati



Slika: Cijene (iznad) i povrati (ispod) indeksa S&P 500

# Svojstva aritmetičkih i logaritamskih povrata

## Izračun cijene (iz prethodne cijene i povrata)

- Aritmetički:

$$P(t) = P(t-1)(1 + R(t))$$

- Logaritamski:

$$P(t) = P(t-1)\exp(r(t))$$

## Ukupni (kumulativni) povrat kroz $T$ vremenskih perioda

- Aritmetički:

$$R_{uk} = (1 + R(1)) \cdot (1 + R(2)) \cdot \dots \cdot (1 + R(T)) - 1 = \prod_{t=1}^T (1 + R(t)) - 1$$

- Logaritamski:

$$r_{uk} = r(1) + r(2) + \dots + r(T) = \sum_{t=1}^T r(t)$$

**Investicija:** Odricanje (danas) od sredstava (novac) na neko vrijeme kako bi se ostvarili budući povrati koji će kompenzirati investitora za

- **Vrijeme** na koji su sredstva uložena
  - ▶ 100 EUR danas "vrijedi" više nego 100 EUR za godinu dana
- Očekivanu stopu **inflacije**
  - ▶ Želimo da naša investicija pokrije rast cijena i troškova koje tim sredstvima plaćamo
- **Rizik:** nesigurnost budućih isplata
  - ▶ Za investiciju s nesigurnijim budućim isplatama (većim rizikom) tražimo veći povrat
  - ▶ Od dvije investicije jednakog (očekivanog) povrata preferiramo onu s manjom nesigurnošću (rizikom)

# Povrat i rizik

- Početna vrijednost investicije: 100.000 EUR, horizont: 1 godina.
- Investicija A

Scenarij	povrat	vjerojatnost povrata	krajnja vrijed- nost
Optimistični	100%	0.2	200.000
Neutralni	0%	0.6	100.000
Pesimistični	-50%	0.2	50.000

- Investicija B

Scenarij	povrat	vjerojatnost povrata	krajnja vrijed- nost
Optimistični	20%	0.3	120.000
Neutralni	0%	0.6	100.000
Pesimistični	-10%	0.1	90.000

# Povrat i rizik

- U ovim primjerima povrat je diskretna slučajna varijabla

$$R \sim \begin{pmatrix} r_1 & r_2 & \dots & r_N \\ p_1 & p_2 & \dots & p_N \end{pmatrix}$$

- Očekivani povrat investicije:

$$E[R] = \sum_{i=1}^N r_i p_i$$

- Rizik investicije – standardna devijacija (volatilnost):

$$\sqrt{\text{Var}[R]} = \sqrt{\sum_{i=1}^N p_i (r_i - E[r_i])^2}$$

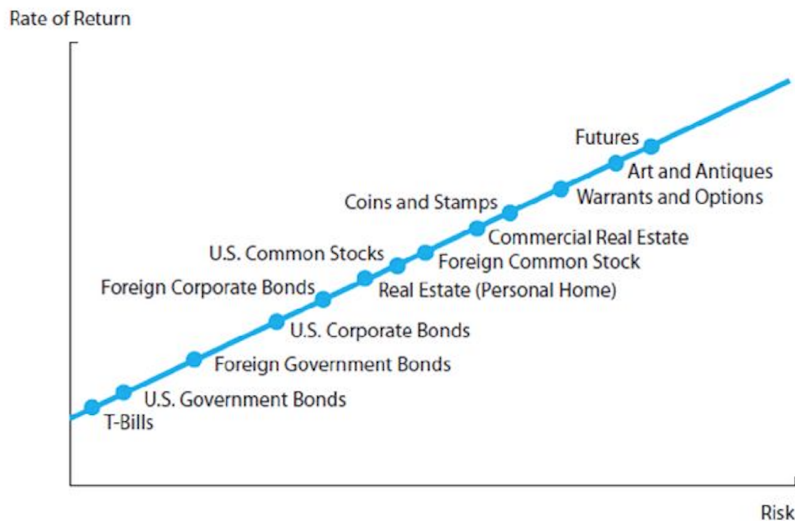
- Koliki su očekivani povrati i rizici investicije A i B? Koju investiciju odabrati?
- Općenito se povrat modelira s neprekidnom slučajnom varijablom s odgovarajućom gustoćom



# Osnovne investicijske klase

- Instrumenti fiksnog prinosa (obveznice)
  - ▶ suštinski slično kreditu
  - ▶ ugovorena dinamika isplata investitoru
- Dionice
  - ▶ vlasnički udjel u trgovačkom društvu
  - ▶ prihod od dividende i/ili kapitalne dobiti
- Nekretnine
  - ▶ vlasnički udjel u stambenom/poslovnom objektu ili zemlji
  - ▶ prihod od najma i/ili kapitalne dobiti
- Izvedenice
  - ▶ vrijednost im ovisi o nekom drugom financijskom instrumentu
  - ▶ opcije, unaprijedni ugovori, swapovi, itd
- Alternativna ulaganja
  - ▶ venture investicije, umjetnine, collectibles
  - ▶ niska likvidnost

# Investicijske klase



# Danas...

- 1 Uvod u financijska tržišta – podatci, povrat i rizik investicija
- 2 **Neprekidne slučajne varijable – pojmovi iz vjerojatnosti i statistike**
- 3 Portfelji i diverzifikacija rizika
- 4 Financijski vremenski nizovi i njihova statistička svojstva
- 5 Analiza glavnih komponenti

# Funkcija distribucije

## Neprekidna slučajna varijabla

Neka je  $(\Omega, \mathfrak{F}, P)$  vjerojatnosni prostor. Preslikavanje  $X : \Omega \rightarrow \mathbb{R}$  nazivamo slučajna varijabla ako je za svaki  $x \in \mathbb{R}$  skup  $\{\omega \in \Omega : X(\omega) < x\}$  događaj, dakle element od  $\mathfrak{F}$ .

## Funkcija distribucije slučajne varijable

Neka je  $(\Omega, \mathfrak{F}, P)$  vjerojatnosni prostor te neka je  $X : \Omega \rightarrow \mathbb{R}$  slučajna varijabla. Funkcija  $F = F_X : \mathbb{R} \rightarrow [0, 1]$  definirana formulom

$$F(x) = F_X(x) = P(X < x), x \in \mathbb{R},$$

zove se funkcija distribucije slučajne varijable  $X$ .

# Funkcija gustoće

## Funkcija gustoće slučajne varijable

Slučajna varijabla  $X : \Omega \rightarrow \mathbb{R}$  je neprekidna slučajna varijabla ako postoji funkcija  $f = f_X : \mathbb{R} \rightarrow [0, \infty]$  takva da vrijedi

$$F_X(x) = \int_{-\infty}^x f_X(t) dt, \forall x \in \mathbb{R}$$

i  $f_X$  se zove vjerojatnosna funkcija gustoće.

## Egzistencija i zadavanje neprekidne slučajne varijable

Svaka funkcija gustoće neprekidne slučajne varijable ima svojstva

$$f(x) \geq 0, \forall x \in \mathbb{R} \text{ te } \int_{-\infty}^{\infty} f(x) dx = 1.$$

Vrijedi i obrat.

# Očekivanje i varijanca

## Očekivanje

Neka je  $X : \Omega \rightarrow \mathbb{R}$  neprekidna slučajna varijabla s funkcijom gustoće  $f_X$ . Ako integral  $\int_{-\infty}^{\infty} |x| f_X(x) dx$  postoji, tada kažemo da slučajna varijabla ima matematičko očekivanje i definiramo

$$E[X] = \int_{-\infty}^{\infty} x f_X(x) dx.$$

## Varijanca

Neka je  $X : \Omega \rightarrow \mathbb{R}$  neprekidna slučajna varijabla s funkcijom gustoće  $f_X$ . Ako integral  $\int_{-\infty}^{\infty} x^2 f_X(x) dx$  postoji, tada kažemo da slučajna varijabla ima varijancu i definiramo

$$\text{Var}(X) = E[(X - E[X])^2].$$

# Kovarijanca

## Kovarijanca

Neka su  $X, Y : \Omega \rightarrow \mathbb{R}$  slučajne varijable koje imaju varijancu, tada se njihova kovarijanca definirana s

$$\text{Cov}(X, Y) = \text{E} [(X - \text{E}[X])(Y - \text{E}[Y])] .$$

## Svojstva očekivanja i varijance

Neka su  $X, Y : \Omega \rightarrow \mathbb{R}$  neprekidne slučajne varijable koje imaju očekivanje, odnosno varijancu. Tada vrijedi

$$\text{E} [aX + bY] = a\text{E}[X] + b\text{E}[Y].$$

$$\text{Var} [aX + bY] = a^2\text{Var}[X] + b^2\text{Var}[Y] + 2ab\text{Cov}(X, Y).$$

# Korelacija

## Pearsonov koeficijent korelacije

Neka su  $X, Y : \Omega \rightarrow \mathbb{R}$  slučajne varijable koje imaju varijance  $\sigma_X^2, \sigma_Y^2$ , tada je njihov Pearsonov koeficijent korelacije dan s

$$\rho_{X,Y} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

## Svojstva koeficijenta korelacije

Neka je  $\rho$  koeficijent korelacije slučajnih varijabli  $X$  i  $Y$ . Tada je  $\rho \in [-1, 1]$  te vrijedi:

- $\rho = 0$  - slučajne varijable  $X$  i  $Y$  nisu linearno povezane (kažemo da su nekorelirane)
- $\rho = 1$  - slučajne varijable su pozitivno korelirane i postoji linearna veza između njih
- $\rho = -1$  - slučajne varijable su negativno korelirane i postoji linearna veza između njih



# Očekivanje, (ko)varijanca i korelacija slučajnog vektora

Za slučajni vektor  $X = [X_1, X_2, \dots, X_N]'$  definiramo:

- Vektor očekivanja

$$\mu_X = [\mu_1, \mu_2, \dots, \mu_N]'$$

gdje je  $\mu_i = E[X_i]$ .

- Matrica kovarijance

$$\Sigma = \begin{bmatrix} \sigma_1^2 & \sigma_{1,2} & \cdots & \sigma_{1,N} \\ \sigma_{1,2} & \sigma_2^2 & \cdots & \sigma_{2,N} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{1,N} & \sigma_{2,N} & \cdots & \sigma_N^2 \end{bmatrix}$$

gdje je  $\sigma_i^2 = \text{Var}[X_i]$ ,  $\sigma_{i,j}^2 = \text{Cov}(X_i, X_j)$ .

- Korelacijska matrica

$$\mathbf{C} = \begin{bmatrix} 1 & \rho_{1,2} & \cdots & \rho_{1,N} \\ \rho_{1,2} & 1 & \cdots & \rho_{2,N} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{1,N} & \rho_{2,N} & \cdots & 1 \end{bmatrix}$$

# Danas...

- 1 Uvod u financijska tržišta – podatci, povrat i rizik investicija
- 2 Neprekidne slučajne varijable – pojmovi iz vjerojatnosti i statistike
- 3 Portfelji i diverzifikacija rizika**
- 4 Financijski vremenski nizovi i njihova statistička svojstva
- 5 Analiza glavnih komponenti

## Diverzifikacija rizika – portfelji

- Nesigurnost budućih isplata ili vrijednosti pojedinih investicija može se smanjiti kombiniranjem više investicija
- Npr. postoji vjerojatnost da će propasti kompanija u čiju dionicu investiramo – no ako odaberemo 100 različitih dionica/kompanija, vjerojatnost da će sve kompanije propasti je puno manja!

Primjer - razmotrimo sljedeću investiciju (portfelj):

- U trenutku  $t_0$ : 1 dionica A vrijednosti 100 EUR i 1 dionica B vrijednosti 300 EUR
- U trenutku  $t_1$  dionica A padne 10%, dionica B naraste 4%
- Koja je vrijednost portfelja u  $t_1$ ?
- Koliki je povrat portfelja?

# Portfelj

## Portfelj

Portfelj je linearna kombinacija investicija s udjelima  $w = [w_1, w_2, \dots, w_N]'$ , čiji povrat je dan s

$$R_p = \sum_{i=1}^N w_i R_i, \quad \sum_{i=1}^N w_i = 1,$$

gdje je  $R_i$  povrat  $i$ -te investicije, a  $w_i$  udjel  $i$ -te investicije.

Očekivani povrat portfelja:

$$E[R_p] = \sum_{i=1}^N w_i E[R_i] = w' \mu_R$$

Rizik portfelja (standardna devijacija, volatilnost):

$$\sqrt{\text{Var}[R_p]} = \sqrt{\sum_{i=1}^N w_i^2 \text{Var}(R_i) + \sum_{i,j=1, i \neq j}^N w_i w_j \text{Cov}(R_i, R_j)} = \sqrt{w' \Sigma w}$$

Napomena: ovi izrazi vrijede samo za aritmetičke povrate!

# Diverzifikacija rizika u portfelju

Primjer: razmotrimo portfelj jednakih težina  $w = [1/N, 1/N, \dots, 1/N]$  od ukupno  $N$  nekoreliranih vrijednosnica koje imaju jednaku volatilnost  $\sigma$ . Kolika je volatilnost portfelja?

## Svojstva varijance aritmetičke sredine slučajnih varijabli

Neka su  $X_i$  slučajne varijable koje imaju varijancu te neka je  $Y = \frac{1}{n} \sum_{i=1}^n X_i$ . Tada vrijedi

❶ ako su varijable  $X_i$  nekorelirane

$$Var(Y) = Var\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \left(\frac{1}{n}\right)^2 \sum_{i=1}^n Var(X_i) = \frac{Var(X)}{n}$$

❷ ako su varijable korelirane s prosječnom korelacijom  $\rho$

$$Var(Y) = \frac{Var(X)}{n} + \frac{n-1}{n} \rho Var(X)$$

# Moderna teorija portfelja

Optimizacijski problem:

$$\min_w w' \Sigma w - \gamma w' \mu_R \quad \text{s.t. } 1'w = 1,$$

uz parametar  $\gamma > 0$ .

- Za svaku vrijednost  $\gamma$  postoji jedan optimalan portfelj
- Svi optimalni portfelji tvore **efikasnu granicu** (*efficient frontier*)

Druge formulacije problema:

- Minimizacija rizika za danu razinu očekivanog povrata:

$$\min_w w' \Sigma w \quad \text{s.t. } w' \mu_R = \mu_P, 1'w = 1$$


,

- Maksimizacija očekivanog povrata uz danu razinu rizika


$$\max_w w' \mu_R \quad \text{s.t. } w' \Sigma w = \sigma_P^2, 1'w = 1$$

.

# Moderna teorija portfelja – efikasna granica



## Primjer – efikasna granica za dvije dionice

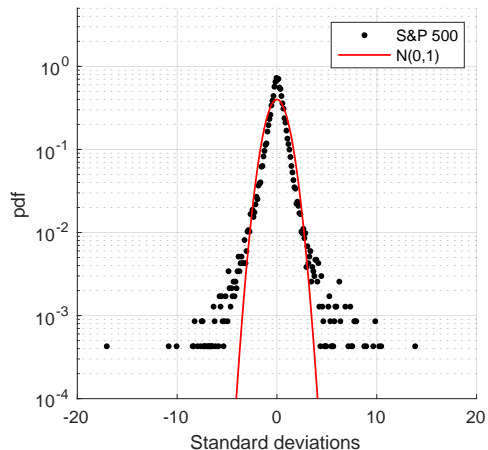





# Danas...

- 1 Uvod u financijska tržišta – podatci, povrat i rizik investicija
- 2 Nепrekidne slučajne varijable – pojmovi iz vjerojatnosti i statistike
- 3 Portfelji i diverzifikacija rizika
- 4 Financijski vremenski nizovi i njihova statistička svojstva**
- 5 Analiza glavnih komponenti

# Teški repovi u razdiobama povrata



# Vremenska zavisnost povrata


## Normalizirana autokorelacijska funkcija

Neka je  $\{X_i, i = 1, \dots, T\}$  niz jednako distribuiranih slučajnih varijabli koje imaju očekivanje  $\mu$  i varijancu  $\sigma^2$ . Normalizirana autokorelacijska funkcija definirana je izrazom

$$f_X(\tau) = \frac{Cov(X_t, X_{t+\tau})}{\sigma^2}$$


# Vremenska zavisnost povrata

Autokorelacija povrata:



# Vremenska zavisnost povrata

Autokorelacija apsolutnih povrata:



# Financijski signali ili financijski vremenski nizovi

- Cijene financijskih instrumenata

- ▶ cijene dionica
- ▶ cijene obveznica
- ▶ cijene opcija
- ▶ itd


- Makroekonomske varijable

- ▶ kamatne stope
- ▶ tečajne liste (valute)
- ▶ bruto domaći proizvod (BDP)
- ▶ itd


- Podatci o kompanijama

- ▶ zarada
- ▶ promet
- ▶ dug
- ▶ itd

# Odnos cijene i zarade




(a) Logaritam S&P 500 indeksa i logaritam odgovarajućih zarada



(b) P/E za S&P 500

# Odnos cijene i zarade





# Danas...

- 1 Uvod u financijska tržišta – podatci, povrat i rizik investicija
- 2 Nепrekidne slučajne varijable – pojmovi iz vjerojatnosti i statistike
- 3 Portfelji i diverzifikacija rizika
- 4 Financijski vremenski nizovi i njihova statistička svojstva
- 5 Analiza glavnih komponenti

# Analiza glavnih komponenti - uvod

Analiza glavnih komponenti bavi se objašnjavanjem kovarijancijske strukture skupa varijabli s nekoliko linearnih kombinacija tih varijabli.

Glavni ciljevi analize glavnih komponenti su:

- redukcija dimenzionalnosti
- interpretacija (identifikacija zajedničkih izvora varijabilnosti)

Algebarski, glavne komponente su određene linearne kombinacije slučajnih varijabli  $X_1, \dots, X_p$ .

Geometrijski, te linearne kombinacije predstavljaju nove koordinatne osi dobivene rotacijom originalnog sustava s  $X_1, \dots, X_p$  kao originalnim osima.

# Analiza glavnih komponenti - uvod

## Linearne kombinacije slučajnih varijabli

- Slučajni vektor  $\mathbf{X} = [X_1, X_2, \dots, X_p]'$ , s kovarijancom  $\Sigma$
- Razmatramo linearne kombinacije:

$$Y_1 = a_{11}X_1 + a_{12}X_2 + \dots + a_{1p}X_p = \mathbf{a}_1' \mathbf{X}$$

$$Y_2 = a_{21}X_1 + a_{22}X_2 + \dots + a_{2p}X_p = \mathbf{a}_2' \mathbf{X}$$

$$\vdots$$

$$Y_p = a_{p1}X_1 + a_{p2}X_2 + \dots + a_{pp}X_p = \mathbf{a}_p' \mathbf{X}$$

- Varijanca i kovarijanca:

$$\text{Var}(Y_i) = \mathbf{a}_i' \Sigma \mathbf{a}_i$$

$$\text{Cov}(Y_i, Y_j) = \mathbf{a}_i' \Sigma \mathbf{a}_j$$

# Glavne komponente

- Prva glavna komponenta:
  - ▶ linearna kombinacija  $\mathbf{a}_1' \mathbf{X}$  koja maksimizira  $\text{Var}(Y_1) = \mathbf{a}_1' \boldsymbol{\Sigma} \mathbf{a}_1$ ,
  - ▶ uz uvjet  $\mathbf{a}_1' \mathbf{a}_1 = 1$ .
- Druga glavna komponenta:
  - ▶ linearna kombinacija  $\mathbf{a}_2' \mathbf{X}$  koja maksimizira  $\text{Var}(Y_2) = \mathbf{a}_2' \boldsymbol{\Sigma} \mathbf{a}_2$ ,
  - ▶ uz uvjete  $\mathbf{a}_2' \mathbf{a}_2 = 1$  i  $\text{Cov}(Y_1, Y_2) = \mathbf{a}_1' \boldsymbol{\Sigma} \mathbf{a}_2 = 0$ .
- $i$ -ta glavna komponenta:
  - ▶ linearna kombinacija  $\mathbf{a}_i' \mathbf{X}$  koja maksimizira  $\text{Var}(Y_i) = \mathbf{a}_i' \boldsymbol{\Sigma} \mathbf{a}_i$ ,
  - ▶ uz uvjete  $\mathbf{a}_i' \mathbf{a}_i = 1$  i  $\text{Cov}(Y_i, Y_j) = \mathbf{a}_i' \boldsymbol{\Sigma} \mathbf{a}_j = 0, \quad \forall j < i$ .

# Glavne komponente

## Glavne komponente - svojstvena dekompozicija kovarijance

Neka je  $\Sigma$  kovarijacijska matrica slučajnog vektora  $\mathbf{X} = [X_1, X_2, \dots, X_p]'$ , s parovima svojstvenih vrijednosti i svojstvenih vektora:  $(\lambda_1, \mathbf{e}_1), (\lambda_2, \mathbf{e}_2), \dots, (\lambda_p, \mathbf{e}_p)$ , tako da vrijedi  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$ . Vrijedi svojstvena dekompozicija kovarijance:

$$\Sigma = \sum_{i=1}^p \lambda_i \mathbf{e}_i \mathbf{e}_i' = \mathbf{E} \mathbf{\Lambda} \mathbf{E}', \quad \mathbf{E} = [\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_p], \mathbf{\Lambda} = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_p)$$

Onda je  $i$ -ta glavna komponenta:

$$Y_i = e_{i1}X_1 + e_{i2}X_2 + \dots + e_{ip}X_p = \mathbf{e}_i' \mathbf{X}.$$

Varijanca i kovarijanca komponenti:

$$\text{Var}(Y_i) = \mathbf{e}_i' \Sigma \mathbf{e}_i = \lambda_i, \quad i = 1, 2, \dots, p.$$

$$\text{Cov}(Y_i, Y_j) = \mathbf{e}_i' \Sigma \mathbf{e}_j = 0, \quad \forall i \neq j.$$

# Glavne komponente

## Glavne komponente - dekompozicija varijance

Zbroj varijanci glavnih komponenti jednak je zbroju varijanci originalnih varijabli:

$$\sigma_1^2 + \sigma_2^2 + \dots + \sigma_p^2 = \sum_{i=1}^p \text{Var}(X_i) = \lambda_1 + \lambda_2 + \dots + \lambda_p = \sum_{i=1}^p \text{Var}(Y_i).$$

- Postotak varijance koju objašnjava  $i$ -ta glavna komponenta:

$$\frac{\lambda_i}{\lambda_1 + \lambda_2 + \dots + \lambda_p}.$$

- Korelacijski koeficijent komponente  $Y_i$  i varijable  $X_j$ :

$$\rho_{Y_i, X_j} = \frac{e_{ij} \sqrt{\lambda_i}}{\sqrt{\sigma_{jj}}}$$

## Svojstvene vrijednosti i vektori - izračun

Za svojstveni vektor  $\mathbf{e}$  i pripadajuću svojstvenu vrijednost  $\lambda_i$  neke matrice  $\Sigma$  vrijedi:

$$\Sigma \mathbf{e} = \lambda \mathbf{e}$$

odnosno:  $(\Sigma - \lambda I)\mathbf{e} = 0$ . Sustav ima netrivialno rješenje kad vrijedi  $|\Sigma - \lambda I| = 0$ .

- Odredimo determinantu s nepoznatom  $\lambda$ , rješavanjem jednadžbe odredimo svojstvene vrijednosti.
- Svaku  $\lambda_i$  uvrstimo i rješavanjem sustava uz  $\mathbf{e}'\mathbf{e} = 1$  izračunamo elemente pripadajućeg svojstvenog vektora.

# Primjer


- Kovarijanca dvije varijable  $X_1$  i  $X_2$ :

$$\Sigma = \begin{bmatrix} 4 & 3 \\ 3 & 9 \end{bmatrix}$$

- Odredite glavne komponente.
- Koliki postotak ukupne varijance objašnjava pojedina komponenta?
- Koja je korelacija pojedine komponente i varijable?



# Glavne komponente multivarijatne normalne varijable



# Glavne komponente standardiziranih varijabli

- Razmotrimo standardizirane varijable:

$$Z_1 = \frac{X_1 - \mu_1}{\sqrt{\sigma_{11}}}$$

$$Z_2 = \frac{X_2 - \mu_2}{\sqrt{\sigma_{22}}}$$

$$\vdots$$

$$Z_p = \frac{X_p - \mu_p}{\sqrt{\sigma_{pp}}}$$

- U matričnoj notaciji:  $\mathbf{Z} = \mathbf{V}^{-1/2}(\mathbf{X} - \boldsymbol{\mu})$ , gdje je  $\mathbf{V}$  dijagonalna matrica s varijancama  $\sigma_i^2$  na dijagonali.
- Matrica kovarijance:  $\text{Cov}(\mathbf{Z}) = \mathbf{V}^{-1/2}(\boldsymbol{\Sigma})\mathbf{V}^{-1/2} = \mathbf{C}$ , gdje je  $\mathbf{C}$  korelacijska matrica slučajnog vektora  $\mathbf{X}$ .

# Glavne komponente standardiziranih varijabli

## Glavne komponente standardiziranih varijabli

Neka je  $\mathbf{R}$  korelacijska matrica slučajnog vektora  $\mathbf{X}$ , s parovima svojstvenih vrijednosti i svojstvenih vektora:  $(\lambda_1, \mathbf{e}_1), (\lambda_2, \mathbf{e}_2), \dots, (\lambda_p, \mathbf{e}_p)$ , tako da vrijedi  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$ . Onda je  $i$ -ta glavna komponenta standardiziranih varijabli  $\mathbf{Z} = [Z_1, Z_2, \dots, Z_p]'$ :

$$Y_i = \mathbf{e}_i' \mathbf{Z} = \mathbf{e}_i' \mathbf{V}^{-1/2} (\mathbf{X} - \boldsymbol{\mu}).$$

- Zbroj varijanci komponenti:

$$\sum_{i=1}^p \text{Var}(Y_i) = \sum_{i=1}^p \text{Var}(Z_i) = p$$

- Korelacijski koeficijent komponente  $Y_i$  i varijable  $Z_j$ :

$$\rho_{Y_i, Z_j} = e_{ij} \sqrt{\lambda_i}$$

# Primjer

- Kovarijanca dvije varijable  $X_1$  i  $X_2$ :

$$\Sigma = \begin{bmatrix} 4 & 3 \\ 3 & 9 \end{bmatrix}$$

- Odredite korelacijsku matricu i glavne komponente standardiziranih varijabli (iz korelacijske matrice)? Kako se mijenjaju u odnosu na glavne komponente iz kovarijance?
- Mijenja li se postotak opisane varijance?
- Mijenjaju li se korelacije komponenti i pojedinih varijabli?

# Glavne komponente uzorka

Populacijsku matricu kovarijance ili korelacije ne poznajemo – ali ih možemo procijeniti iz podataka:

- Podatci:  $n$  opservacija  $p$ -dimenzionalnog slučajnog vektora  $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n]$
- Uzoračka matrica kovarijance:

$$\hat{\Sigma} = \frac{1}{n-1} \sum_{i=1}^n [(\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})'] , \quad \bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$$

- Uzoračka matrica korelacije:

$$\hat{\mathbf{C}} = \mathbf{D}^{-1} \hat{\Sigma} \mathbf{D}^{-1}, \quad \mathbf{D} = \text{diag}(\hat{\sigma}_1, \hat{\sigma}_2, \dots, \hat{\sigma}_p)$$

- Koristimo svojstvenu dekompoziciju uzoračkih procjena matrica u analizi.

# Broj glavnih komponenti

- Komponente koje objašnjavaju jako malo varijance nisu bitne u analizi.
  - ▶ Što ako je  $n < p$ , koliko ne-nul svojstvenih vrijednosti postoji?
- Pri odabiru broja glavnih komponenti dobro je imati na umu:
  - ▶ Količina i udio objašnjene varijance
  - ▶ Relativne vrijednosti objašnjene varijance
  - ▶ Interpretacija komponenti
- Nekoliko metoda za odabir broja komponenti:
  - ▶ Zadržavamo sve komponente koje objašnjavaju bar neki udio varijance (npr. barem 5%).
  - ▶ Zadržavamo broj komponenti koji ukupno objašnjava neki udio ukupne varijance (npr. 90%).
  - ▶ *Scree plot* - tražimo nagli pad u postotku objašnjene varijance.

# Svojstva glavnih komponenti

- Rotacije komponenti:

- ▶ Moguće je promijeniti predznak svojstvenim vektorima (pomnožiti s  $-1$ ).
- ▶ Radi interpretacije, vektori se mogu rotirati tako da je većina elemenata pozitivno, ili da je zbroj elemenata pozitivan.

- Rekonstrukcija podataka:

- ▶ Svaka observacija  $\mathbf{x}_j$  se može rekonstruirati kao linearna kombinacija prvih  $q$  glavnih komponenti:

$$\hat{\mathbf{x}}_j = \hat{y}_{j1}\hat{\mathbf{e}}_1 + \hat{y}_{j2}\hat{\mathbf{e}}_2 + \dots + \hat{y}_{jq}\hat{\mathbf{e}}_q = (\mathbf{x}'_j\hat{\mathbf{e}}_1)\hat{\mathbf{e}}_1 + (\mathbf{x}'_j\hat{\mathbf{e}}_2)\hat{\mathbf{e}}_2 + \dots + (\mathbf{x}'_j\hat{\mathbf{e}}_q)\hat{\mathbf{e}}_q$$

- ▶ Rekonstrukcija će biti savršena ako koristimo svih  $q = p$  komponenti, u protivnom, za  $q < p$  će postojati rekonstrukcijska greška koja iznosi  $\hat{y}_{jq+1}\hat{\mathbf{e}}_{q+1} + \dots + \hat{y}_{jp}\hat{\mathbf{e}}_p$ .
- ▶ Rekonstrukcijska greška korisna je pri analizi potencijalnih stršućih vrijednosti.

# PCA u financijama

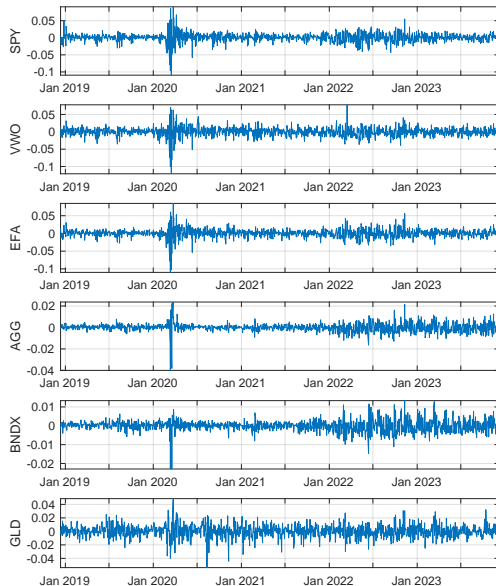

Razmatramo skup imovina (fondova):

Oznaka	Naziv	Vrsta imovine
SPY	<i>SPDR S&amp;P 500 ETF Trust</i>	Dionice - USA
AGG	<i>iShares Core U.S. Aggregate Bond ETF</i>	Obveznice - USA
VWO	<i>Vanguard FTSE Emerging Markets ETF</i>	Dionice - tržišta u razvoju
EFA	<i>iShares MSCI EAFE ETF</i>	Dionice - razvijena tržišta izvan USA
BNDX	<i>Vanguard Total International Bond ETF</i>	Obveznice - razvijena tržišta izvan USA
GLD	<i>SPDR Gold Trust</i>	Zlato

- Analiziramo dnevne cijene u zadnjih 5 godina (ukupno 1258 dnevnih cijena za svaki fond)
- Koristimo (aritmetičke) dnevne povrate koje računamo iz cijena.



# PCA u financijama - cijene i povrati



# PCA u financijama - kovarijanca i korelacija povrata


Uzoračka kovarijanca povrata:

$$\begin{bmatrix} 0.1785 & 0.1378 & 0.1465 & 0.0084 & 0.0067 & 0.0126 \\ & 0.1809 & 0.1401 & 0.0080 & 0.0057 & 0.0232 \\ & & 0.1552 & 0.0097 & 0.0062 & 0.0217 \\ & & & 0.0168 & 0.0096 & 0.0150 \\ & & & & 0.0093 & 0.0101 \\ & & & & & 0.0882 \end{bmatrix} \cdot 10^{-3}$$

- Teško interpretirati, u praksi se često preferiraju korelacije ili anualizirane volatilnosti

# PCA u financijama - kovarijanca i korelacija povrata

Uzoračka korelacija:

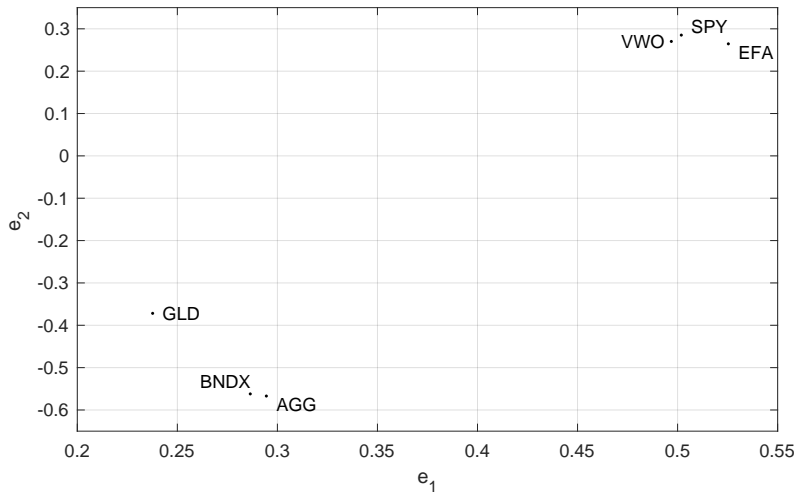


# PCA u financijama - svojstvena dekompozicija korelacijske matrice

- Koeficijenti glavnih komponenti:


	$e_1$	$e_2$	$e_3$	$e_4$	$e_5$	$e_6$
<i>SPY</i>	0.50	0.29	-0.11	-0.49	-0.33	0.55
<i>VWO</i>	0.50	0.27	0.05	0.57	0.53	0.25
<i>EFA</i>	0.53	0.26	0.00	-0.07	-0.19	-0.78
<i>AGG</i>	0.29	-0.57	-0.28	0.49	-0.52	0.09
<i>BNDX</i>	0.29	-0.56	-0.34	-0.42	0.55	-0.09
<i>GLD</i>	0.24	-0.37	0.89	-0.11	-0.03	0.05
Varianca	2.91	1.78	0.74	0.24	0.23	0.10
Varianca [%]	48.5%	29.7%	12.4%	3.9%	3.8%	1.7%
Varianca - kum. [%]	48.5%	78.2%	90.6%	94.5%	98.3%	100.0%

## PCA u financijama - vizualizacija podataka u novom prostoru



# PCA u financijama - broj komponenti u analizi

Scree plot:



# PCA u financijama - komponente kao portfelji


Glavne komponente su portfelji (tzv. svojstveni portfelji):

- Negativne težine predstavljaju kratke pozicije.
- Za potrebe analize koeficijente glavnih komponenti možemo rotirati:
  - ▶ tako da suma težina portfelja bude pozitivna
  - ▶ tako da srednji povrat portfelja bude pozitivan
- Ponekad želimo dodatno skalirati težine (npr. tako da vrijedi  $\sum w_i = 1$  ili  $\sum |w_i| = 1$ ).

Primjer – težine rotirane tako da srednji povrat svakog portfelja bude pozitivan, bez skaliranja:

	$w_1$	$w_2$	$w_3$
<i>SPY</i>	0.50	0.29	-0.11
<i>VWO</i>	0.50	0.27	0.05
<i>EFA</i>	0.53	0.26	0.00
<i>AGG</i>	0.29	-0.57	-0.28
<i>BNDX</i>	0.29	-0.56	-0.34
<i>GLD</i>	0.24	-0.37	0.89

# PCA u financijama - komponente kao portfelji





- Johnson, R. A., and D. W. Wichern, Applied Multivariate Statistical Analysis - poglavlja 8.1 - 8.4